

Ширококолонкова база даних

Ширококолонкова база даних — це тип бази даних, яка зберігає дані, використовуючи колонково-орієнтовану модель.


Ширококолонкові база даних є підмножиною NoSQL баз даних типу ключ-значення. Вони використовують таблиці, рядки та стовпці, але на відміну від реляційних баз даних, стовпці можуть відрізнятися від рядка до рядка.

Таблиці можуть створюватися, змінюватися і видалятися під час роботи бази даних.

Ці сховища найкраще використовувати, коли ви знаєте запити заздалегідь і моделюєте таблиці навколо них.

Вони дозволяють дуже швидко запитувати конкретні частини даних, але не цілі рядки, тому важливо розуміти, що ви будете запитувати, перш ніж створювати систему.

Широкостовпцеві сховища працюють дуже швидко, але є специфічними щодо запитів.



Також можна називати:

Wide-column store

Сховище зі широким стовпцем

Колонкова база даних

База даних сімейства колонок

Бази даних сімейства стовпців

Колонково-орієнтована база даних

Ширококолонкова база даних

Широкостовпцеві сховища

Колонкова база даних


Колонкове сховище

Ширококолонкова база даних

Ширококолонкова база даних — це тип NoSQL баз даних орієнтованої на колонку бази даних, яка зберігає дані в таблицях, де імена та формати окремих атрибутів можуть змінюватися від рядка до рядка.


Такі бази даних призначені для обробки великих обсягів даних у гнучких структурах.

Дані зберігаються в записах з динамічними колонками, де імена колонок і ключі записів не є фіксованими, що дозволяє мати мільярди колонок. Це робить їх **двовимірними сховищами ключ-значення**.



Кожен рядок в одній колонковій родині може мати унікальний набір колонок, зберігаючи лише необхідні дані без порожніх полів. Така гнучкість робить ширококолонкові сховища ідеальними для додатків, які потребують обробки великих обсягів даних з різнорідними структурами.

Структура бази даних зберігання колонок




Ключовий простір, що містить сімейства колонок.

Колонкові бази даних використовують концепцію, яка називається **ключовий простір** (**keyspace**).

Ключовий простір подібний на схему в реляційній моделі.

Ключовий простір містить усі сімейства колонок (схожі на таблиці в реляційній моделі), які містять рядки, що містять колонки.

Структура бази даних зберігання колонок



Детальніший погляд на сімейство колонок:

UserProfile

Bob	emailAddress	gender	age
	bob@example.com	male	35
	1465676582	1465676582	1465676582
Britney	emailAddress	gender	
	brit@example.com	female	
	1465676432	1465676432	
Tori	emailAddress	country	hairColor
	tori@example.com	Sweden	Blue
	1435636158	1435636158	1465633654

Сімейство колонок, що містить 3 рядки.
Кожен рядок містить свій власний набір колонок.

Сімейство колонок складається з кількох рядків.

Кожен **рядок** може містити різну кількість колонок порівняно з іншими рядками. І колонки не обов'язково повинні збігатися з колонками в інших рядках (тобто вони можуть мати різні імена колонок, типи даних тощо).

Кожна **колонка** належить своєму рядку. Вона не поширюється на всі рядки, як у реляційній базі даних.


Кожна колонка містить пару ключ/значення разом із часовою позначкою(Unix/Epoch).

Сховища з широкими стовпцями використовують сімейства колонок для групування пов'язаних даних.

Окремі записи не обов'язково мають однакові колонки.

Ця структура ідеальна для аналітичних навантажень.

Структура бази даних зберігання колонок



Ось розбір кожного елемента в рядку:

Ключ рядка. Кожен рядок має унікальний ключ, який є унікальним ідентифікатором для цього рядка.

Колонка. Кожна колонка містить ім'я, значення та часову мітку.


Ім'я. Це ім'я пари ім'я/значення (ключ/значення).

Значення. Це значення пари ім'я/значення (ключ/значення).

Часова мітка. Це дата і час вставки даних. Часова мітка може використовуватися для визначення найновішої версії даних.

Ширококолонкова база даних – Підсумок

Ширококолонкові бази даних — це тип баз даних, оптимізованих для зберігання та обробки великих обсягів даних у колонковому форматі.



ключовий простір →

сімейство колонок →

рядки →

колонки →


пари ключ/значення + часова мітка

UserProfile			
Bob	emailAddress	gender	age
	bob@example.com	male	35
	1465676582	1465676582	1465676582
Britney	emailAddress	gender	
	brit@example.com	female	
	1465676432	1465676432	
Tori	emailAddress	country	hairColor
	tori@example.com	Sweden	Blue
	1435636158	1435636158	1465633654

Row Key	Column	Column	Column
	Name	Name	Name
	Value	Value	Value
	Timestamp	Timestamp	Timestamp

Концепція ширококолонкових БД. Суперсімейство колонок

Це зображення ілюструє концепцію ширококолонкових баз даних, де використовується структура з **рядковими ключами**, **сімействами колонок** та **суперсімействами колонок**.



Така структура дозволяє ефективно зберігати і обробляти великі обсяги даних в ширококолонкових базах даних, таких як Cassandra чи HBase, які добре працюють з даними у табличній структурі з різними категоріями властивостей для кожної сутності.

1. Super Column Family (Суперсімейство колонок)

це більш високий рівень групування, який об'єднує кілька сімейств колонок, що стосуються однієї сутності (в даному випадку, компанії). У прикладі вся структура входить до суперсімейства під назвою "companies" (компанії).

2. Row Key (Рядковий ключ)

це унікальний ідентифікатор рядка. У прикладі, рядковий ключ "1" представляє одну сутність або запис, в якому зберігається інформація про певну компанію.

3. Column Family (Сімейство колонок)

це група, яка об'єднує колонки зі спільним призначенням. На зображенні є два сімейства колонок: **address** (адреса) та **website** (вебсайт). Вони містять інформацію про адресу компанії та вебсайт відповідно.

4. Column (Колонка)

кожна окрема характеристика або атрибут. Наприклад, у сімействі колонок "address" є колонки: **city** (місто), **state** (штат) та **street** (вулиця). У сімействі "website" є колонки: **subdomain** (піддомен), **domain** (домен) і **protocol** (протокол).

Приклад сімейств колонок і суперколонок

Column Family :
Users


Keys	Columns		
Peter	Name Peter...	Number 234786459	Mobile Phone 994398909
Joseph	Name Joseph	Number 234786459	

Super Column Family :
Services

Keys	Super Columns		
Peter	Voice	Type Default	Balance 20
	SMS	Type Default	Amount 10
Joseph	Voice	Type Enterprise	Balance 60

Типові сценарії використання

Ширококолонкові бази даних ідеально підходять для випадків використання, які потребують обробки великих наборів даних, розподілених по декількох вузлах бази даних, особливо коли колонки можуть відрізнятися для кожного рядка. Вони чудово справляються з обробкою надзвичайно великих обсягів даних, де швидкість є критично важливою.



1

Big Data

Fast searching of massive amounts of data

2

Inventory Management

Manages large amounts of real-time inventory

3

Real-Time Analytics

Allows developers to gain real-time access to operational data

Аналітика та бізнес-інтелект (BI)

Ідеально підходять для складних аналітичних запитів, які потребують обробки великих обсягів даних. Використовуються для швидкого аналізу даних та отримання бізнес-інсайтів.

Обробка великих даних

Використовуються в системах, де потрібно обробляти та аналізувати великі обсяги даних у реальному часі. Забезпечують ефективну обробку та зберігання даних у масштабах петабайтів.

Дані журналів

Зберігання та аналіз великих обсягів логів для моніторингу та діагностики систем.

Дані сенсорів IoT (Інтернет речей)

Збір та обробка даних від сенсорів у реальному часі.

Дані часових рядів

Моніторинг температури, фінансові торги та інші дані, що змінюються з часом.

Дані на основі атрибутів

Зберігання та аналіз даних, таких як уподобання користувачів або характеристики обладнання.

Аналітика в реальному часі

Використовуються для швидкого аналізу даних у реальному часі, що дозволяє приймати оперативні рішення.

Ключові переваги ширококолонкових сховищ

Стиснення

Колонкові сховища дуже ефективні у стисненні даних та/або їх розподілі. Завдяки зберіганню даних по колонках, такі бази даних можуть ефективніше стискати дані, оскільки дані в одній колонці часто мають схожі значення.

Агрегаційні запити


Завдяки своїй структурі, колонкові бази даних особливо добре справляються з агрегаційними запитами (такими як SUM, COUNT, AVG тощо).

Масштабованість

Колонкові бази даних дуже масштабовані. Вони добре підходять для масово-паралельної обробки (MPP), яка передбачає розподіл даних по великому кластеру машин — часто тисячам машин.

Швидке завантаження та запити

Колонкові сховища можуть завантажуватися надзвичайно швидко. Таблиця з мільярдом рядків може бути завантажена за кілька секунд. Ви можете почати виконувати запити та аналіз майже відразу.



Ключові переваги ширококолонкових сховищ

Продуктивність

Колонкові бази даних оптимізовані для читання великих обсягів даних, що робить їх ідеальними для аналітичних задач, де потрібно швидко обробляти та аналізувати великі набори даних.

Гнучка схема/структури даних

Колонкові сховища дозволяють кожному рядку мати унікальний набір колонок, зберігаючи лише необхідні дані без порожніх полів. Це забезпечує легку адаптацію до змін у вимогах та зберігання різномірних даних в одній базі даних.

Висока доступність

Колонкові сховища розподілені по багатьох серверах, що забезпечує доступність даних навіть у випадку виходу з ладу окремих серверів завдяки реплікації. Це робить їх надійними для критично важливих додатків.



Недоліки ширококолонкових сховищ

Складність проектування схеми

Проектування схеми є складним, оскільки дані потрібно денормалізувати та структурувати для ефективного запиту.

Не призначені для складних запитів

Не призначені для складних запитів, що включають об'єднання (joins), агрегації або підзапити.

Кінцева узгодженість


Багато ширококолонкових сховищ дотримуються принципу кінцевої узгодженості, що означає, що дані можуть бути тимчасово неконсистентними, але з часом стануть узгодженими.



Приклади коду та запитів

База даних	Приклад створення таблиці	Приклад вставки даних	Приклад запиту даних
Apache Cassandra	<pre>-- Створення ключового простору CREATE KEYSPACE my_keyspace WITH replication = {'class': 'SimpleStrategy', 'replication_factor': 3}; -- Використання ключового простору USE my_keyspace; -- Створення таблиці CREATE TABLE users (user_id UUID PRIMARY KEY, first_name TEXT, last_name TEXT, email TEXT);</pre>	<pre>-- Вставка даних INSERT INTO users (user_id, first_name, last_name, email) VALUES (uuid(), 'John', 'Doe', 'john.doe@example.com');</pre>	<pre>-- Запит даних SELECT * FROM users WHERE user_id = some_uuid;</pre>
Apache HBase	<pre>-- Підключення до HBase Shell hbase shell -- Створення таблиці create 'users', 'info'</pre>	<pre>-- Вставка даних put 'users', 'row1', 'info:first_name', 'John' put 'users', 'row1', 'info:last_name', 'Doe' put 'users', 'row1', 'info:email', 'john.doe@example.com'</pre>	<pre>-- Запит даних get 'users', 'row1'</pre>
Google Bigtable	<pre>from google.cloud import bigtable from google.cloud.bigtable import column_family # Підключення до Bigtable client = bigtable.Client(project='my-project-id', admin=True) instance = client.instance('my-instance-id') table = instance.table('users') # Створення таблиці if not table.exists(): table.create() cf1 = column_family.MaxVersionsGCRule(2) column_families = {'info': cf1} table.create(column_families=column_families)</pre>	<pre># Вставка даних row_key = 'user1' row = table.direct_row(row_key) row.set_cell('info', 'first_name', 'John') row.set_cell('info', 'last_name', 'Doe') row.set_cell('info', 'email', 'john.doe@example.com') row.commit()</pre>	<pre># Запит даних row = table.read_row(row_key) print(row.cells['info']['first_name'][0].value) print(row.cells['info']['last_name'][0].value) print(row.cells['info']['email'][0].value)</pre>
Azure Cosmos DB	<pre>from azure.cosmos import CosmosClient, PartitionKey # Підключення до Azure Cosmos DB client = CosmosClient('your_cosmos_account_uri', 'your_cosmos_account_key') # Створення бази даних database = client.create_database_if_not_exists(id='my_database') # Створення контейнера container = database.create_container_if_not_exists(id='users', partition_key=PartitionKey(path='/user_id'))</pre>	<pre># Вставка даних user_item = { 'user_id': 'user1', 'first_name': 'John', 'last_name': 'Doe', 'email': 'john.doe@example.com' } container.create_item(body=user_item)</pre>	<pre># Запит даних query = "SELECT * FROM users u WHERE u.user_id = 'user1'" items = list(container.query_items(query=query, enable_cross_partition_query=True)) for item in items: print(item)</pre>

Рейтинг ширококолонкових баз даних



Rank			DBMS	Database Model	Score		
Nov 2024	Oct 2024	Nov 2023			Nov 2024	Oct 2024	Nov 2023
1.	1.	1.	Apache Cassandra	Wide column, Multi-model	97.71	+0.10	-11.45
2.	2.	2.	Apache HBase	Wide column	25.25	-1.94	-8.91
3.	3.	3.	Microsoft Azure Cosmos DB	Multi-model	23.95	-0.55	-10.16
4.	4.	4.	Datastax Enterprise	Wide column, Multi-model	4.91	+0.17	-2.35
5.	5.	5.	ScyllaDB	Wide column, Multi-model	3.88	+0.14	-2.68
6.	7.	6.	Microsoft Azure Table Storage	Wide column	3.09	-0.16	-2.99
7.	6.	8.	Apache Accumulo	Wide column	3.08	-0.23	-1.06
8.	8.	7.	Google Cloud Bigtable	Multi-model	2.93	+0.02	-1.34
9.	9.	10.	Amazon Keyspaces	Wide column	1.00	-0.01	+0.02
10.	10.	9.	HPE Ezmeral Data Fabric	Multi-model	0.83	-0.05	-0.41
11.	11.	11.	Elassandra	Wide column, Multi-model	0.29	0.00	-0.23
12.	12.	12.	Alibaba Cloud Table Store	Wide column	0.20	-0.04	-0.06
13.	13.	13.	SWC-DB	Wide column, Multi-model	0.01	+0.00	-0.04

Apache Cassandra — розподілена база даних з високою доступністю та масштабованістю без єдиної точки відмови, підтримує моделі даних на основі колонок, популярна для додатків з високими вимогами до продуктивності та надійності.

Apache HBase — розподілена, масштабована база даних, що працює поверх Hadoop, забезпечує швидкий доступ до великих обсягів даних і підтримує колонкові моделі, часто використовується для обробки великих даних у реальному часі.

Azure Cosmos DB — глобально розподілена база даних, що підтримує кілька моделей даних (документи, граfi, ключ-значення, колонки), забезпечує високу доступність, низьку затримку та автоматичне масштабування, ідеальна для додатків з глобальною доступністю та продуктивністю.

Приклади ширококолонкових база даних



Google
BigTable



Azure Cosmos DB



SCYLLA



ДЯКУЮ ЗА УВАГУ!